LAPORAN PRAKTIKUM 3: CLASSIFICATION DENGAN ENSEMBLE METHOD & CLASS IMBALANCE

Nama: Sandi Suryo Nugroho

NRP: 5054251020

Dataset: https://www.kaggle.com/mlg-ulb/creditcardfraud

1. Deskripsi Dataset dan Tujuan

Dataset yang digunakan dalam praktikum ini adalah dataset Credit Card Fraud Detection yang diperoleh dari Kaggle. Dataset ini memuat data transaksi kartu kredit dengan total 284.807 baris dan 31 kolom. Atribut dalam dataset ini mencakup variabel waktu (Time), fitur numerik hasil transformasi PCA (V1 hingga V28), nominal transaksi (Amount), serta variabel target biner (Class).

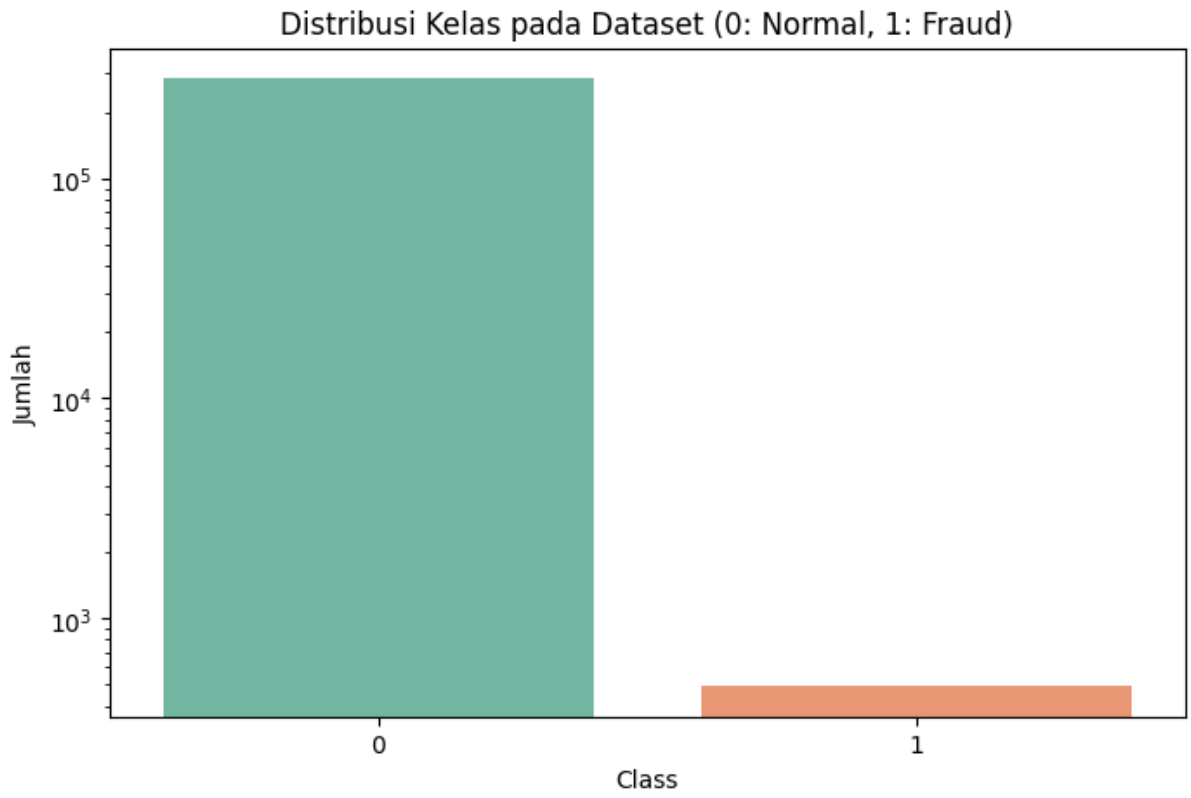
Tujuan dari praktikum ini adalah membangun model klasifikasi menggunakan ensemble method (Random Forest) dan menangani permasalahan ketidakseimbangan kelas (class imbalance) menggunakan teknik SMOTE (Synthetic Minority Over-sampling Technique).

2. Exploratory Data Analysis (EDA) dan Pembersihan Data

Tidak ditemukan adanya nilai yang hilang (missing value) pada seluruh kolom dataset (jumlah maksimum missing value = 0). Ditemukan sebanyak 1.081 baris data duplikat sebelum dilakukan pembersihan. Baris data duplikat dihapus. Setelah penghapusan, dimensi dataset menjadi 283.726 baris dan 31 kolom.

Distribusi Kelas Target:

> **Kelas 0 (Transaksi Normal):** 284.315 data (99,83%).
>
> **Kelas 1 (Transaksi Fraud):** 492 data (0,17%).
>
> Distribusi ini menunjukkan tingkat ketidakseimbangan kelas (class imbalance) yang sangat ekstrem.



3. Preprocessing Data & Penanganan Class Imbalance (SMOTE)

Dataset dipisahkan menjadi fitur independen (seluruh kolom kecuali Class) dan variabel target (Class). Dataset dibagi menjadi data latih (80%) dan data uji (20%) menggunakan train_test_split dengan opsi stratify=y dan random_state=42.

Jumlah Data Latih: 226.980 baris.

Jumlah Data Uji: 56.746 baris.

- **Resampling Menggunakan SMOTE:**
    - **Sebelum SMOTE (Data Latih):** Kelas 0 sebanyak 226.602 data dan Kelas 1 sebanyak 378 data.
    - **Sesudah SMOTE (Data Latih):** Jumlah sampel Kelas 1 disamakan dengan Kelas 0 sehingga masing-masing kelas memiliki 226.602 data.

4. Eksperimen dan Evaluasi Model

Eksperimen klasifikasi dilakukan menggunakan algoritma Random Forest Classifier (random_state=42, n_jobs=-1) pada dua kondisi data latih:

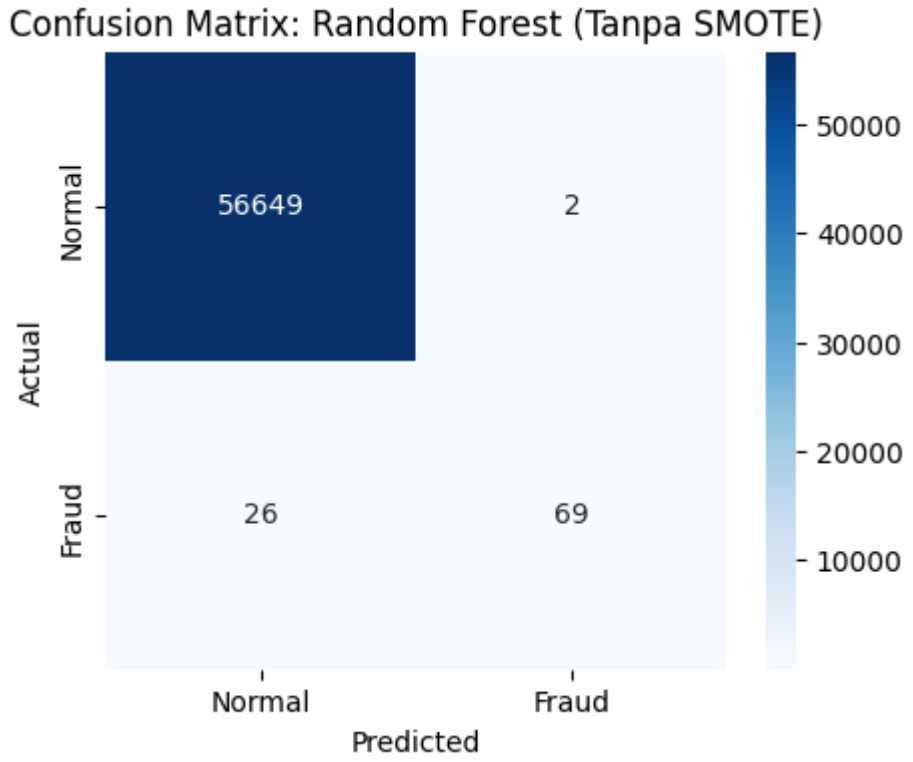
A. Random Forest (Tanpa SMOTE)

```
===== Evaluasi Random Forest (Tanpa SMOTE) =====
Classification Report:
              precision    recall  f1-score   support

           0       1.00      1.00      1.00     56651
           1       0.97      0.73      0.83        95

    accuracy                           1.00     56746
   macro avg       0.99      0.86      0.92     56746
weighted avg       1.00      1.00      1.00     56746

ROC-AUC Score: 0.9239444837225895
```



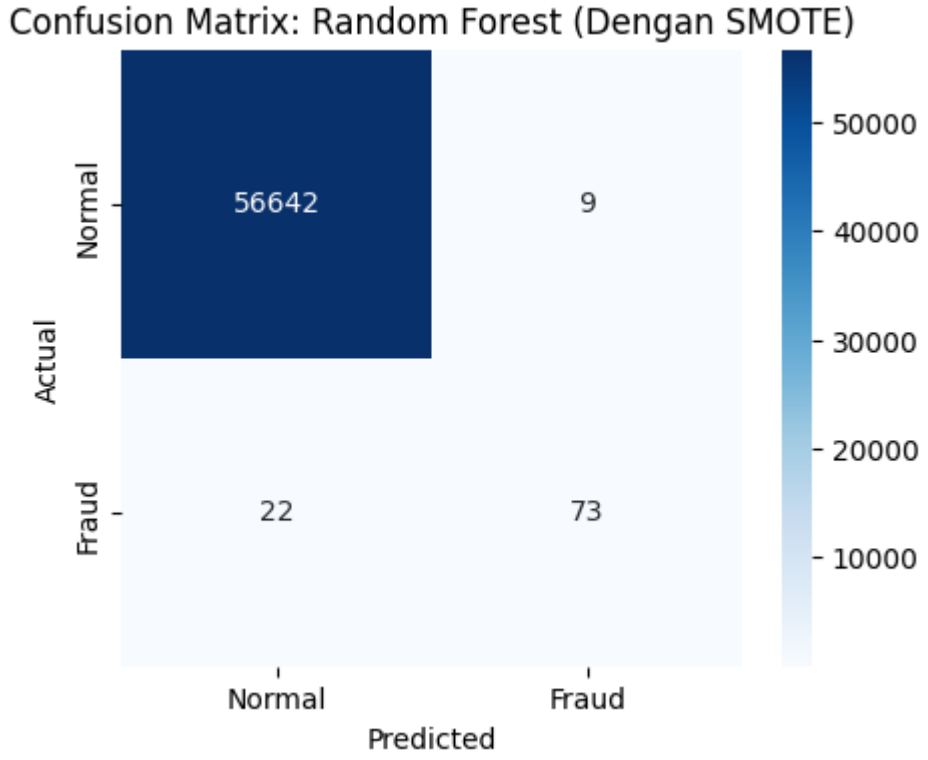
B. Random Forest (Dengan SMOTE)

```
===== Evaluasi Random Forest (Dengan SMOTE) =====
Classification Report:
              precision    recall  f1-score   support

           0       1.00      1.00      1.00     56651
           1       0.89      0.77      0.82        95

    accuracy                           1.00     56746
   macro avg       0.94      0.88      0.91     56746
weighted avg       1.00      1.00      1.00     56746

ROC-AUC Score: 0.9608973316771479
```



5. Analisis Hasil dan Pembahasan

Penerapan SMOTE berhasil meningkatkan nilai **recall** pada kelas fraud dari 0,73 menjadi 0,77. Berdasarkan confusion matrix, jumlah transaksi penipuan yang gagal dideteksi (False Negatives) menurun dari 26 menjadi 22 kasus, sedangkan sampel penipuan yang terdeteksi dengan benar (True Positives) meningkat dari 69 menjadi 73 kasus.

Peningkatan recall menyebabkan penurunan **precision** dari 0,97 menjadi 0,89. Hal ini terjadi karena jumlah alarm palsu (False Positives) meningkat dari 2 menjadi 9 kesalahan prediksi pada transaksi normal.

Kemampuan model secara keseluruhan dalam membedakan transaksi normal dan fraud meningkat signifikan, ditandai dengan kenaikan nilai **ROC-AUC** dari 0,9239 menjadi 0,9609. Nilai **F1-Score** sedikit mengalami penurunan dari 0,83 menjadi 0,82 karena dampak penurunan precision.

Dalam konteks deteksi penipuan kartu kredit, kerugian akibat meloloskan transaksi penipuan (False Negative) jauh lebih mendasar dan berisiko tinggi secara finansial dibandingkan menangani sedikit alarm palsu (False Positive). Oleh karena itu, penggunaan model Random Forest dengan SMOTE lebih direkomendasikan.

6. Ringkasan Akhir

Melalui proses pembersihan data, penanganan ketidakseimbangan kelas menggunakan SMOTE, dan pemodelan ensemble dengan Random Forest, model terbukti mampu meningkatkan deteksi pada kelas terisolasi (fraud). Penerapan SMOTE secara signifikan meningkatkan nilai sensitivitas (recall) dan skor ROC-AUC model.