LAPORAN PRAKTIKUM 2: PRAPROSES DATA

Nama: Sandi Suryo Nugroho
NRP: 5054251020

Dataset: House Prices - Advanced Regression Techniques (train.csv)

1. Deskripsi Dataset

Dataset yang digunakan dalam praktikum ini adalah dataset House Prices dari Kaggle. Data ini memuat berbagai atribut yang memengaruhi harga jual rumah, yang umumnya digunakan untuk pemodelan regresi.
Dataset train.csv memiliki **1.460 baris** data dan **81 kolom**.

2. Pembersihan Data (Data Cleaning)

Tahap pertama praproses adalah mengidentifikasi dan menangani *missing values* (nilai yang hilang) agar tidak menyebabkan error pada model.

```
Persentase Nilai Hilang:
PoolQC          99.520548
MiscFeature     96.301370
Alley           93.767123
Fence           80.753425
MasVnrType      59.726027
FireplaceQu     47.260274
LotFrontage     17.739726
GarageType       5.547945
GarageYrBlt      5.547945
GarageFinish     5.547945
GarageQual       5.547945
GarageCond       5.547945
BsmtExposure     2.602740
BsmtFinType2     2.602740
BsmtQual         2.534247
BsmtCond         2.534247
BsmtFinType1     2.534247
MasVnrArea       0.547945
Electrical       0.068493
dtype: float64

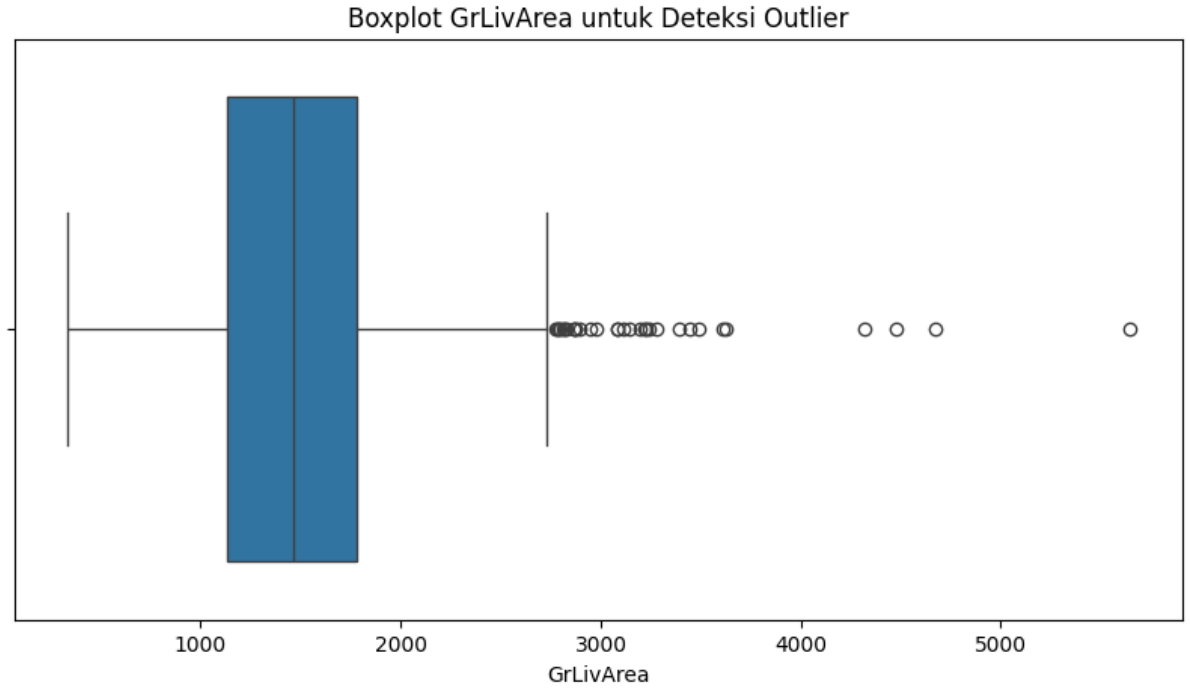
Kolom yang dihapus (>50% hilang): ['Alley', 'MasVnrType', 'PoolQC', 'Fence', 'MiscFeature']
```

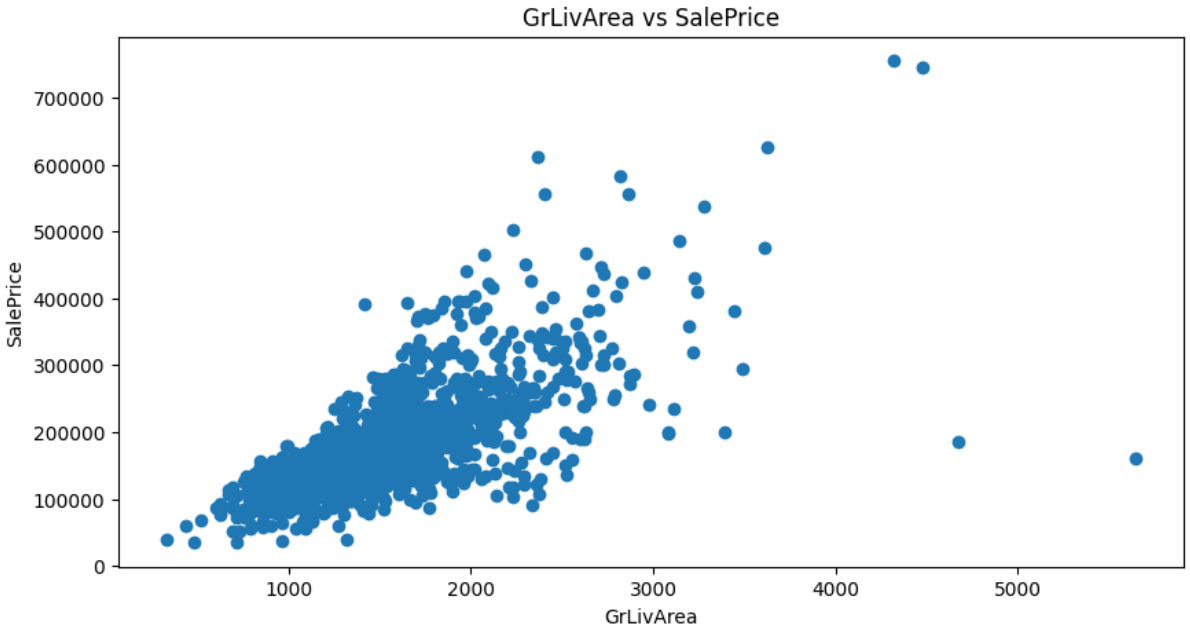
Penghapusan Kolom:
Terdapat beberapa atribut yang memiliki proporsi nilai hilang sangat besar (lebih dari 50%). Atribut tersebut adalah PoolQC (>90% hilang), MiscFeature (>90% hilang), Alley (>90% hilang), dan Fence (>80% hilang). Karena kekurangan informasi yang terlalu parah, kolom-kolom ini dihapus secara permanen dari dataset.

Imputasi Nilai Hilang:
Untuk sisa atribut yang memiliki *missing values* dalam jumlah kecil-menengah, dilakukan pengisian nilai. Pada atribut numerik (seperti LotFrontage), nilai yang hilang diisi dengan median dari kolom tersebut karena median lebih tahan terhadap *outlier*. Untuk atribut kategorikal (seperti fitur garasi atau *basement*), nilai yang hilang diisi dengan modus. Setelah proses ini, dataset memiliki 0 nilai hilang.

3. Deteksi dan Penanganan Outlier

Deteksi outlier dilakukan pada atribut numerik kunci, seperti luas area tempat tinggal (GrLivArea), menggunakan visualisasi *Boxplot* dan *Scatter Plot* terhadap atribut target (SalePrice).





Berdasarkan grafik *scatter plot*, ditemukan adanya pencilan ekstrem di mana terdapat rumah dengan area yang sangat luas (lebih dari 4.000 *square feet*) tetapi dijual dengan harga yang sangat tidak wajar (di bawah $300.000). Data seperti ini dapat merusak garis regresi model. Oleh karena itu, baris data yang memenuhi kriteria tersebut dihapus. Setelah penghapusan, dimensi data berkurang menjadi 1.458 baris.

4. Transformasi Data

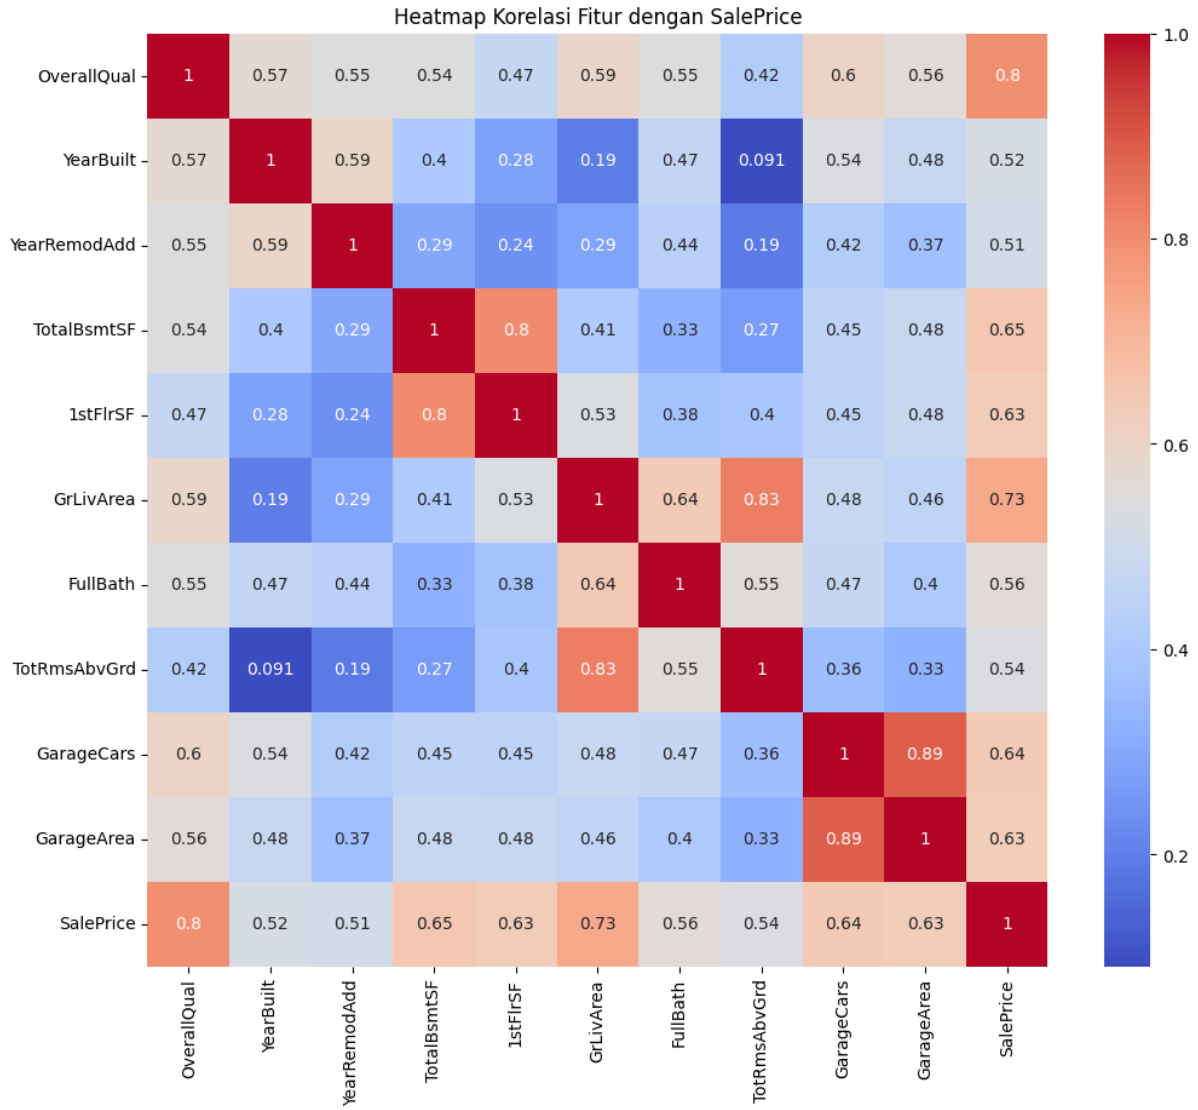
Sebelum transformasi, variabel dipisah menjadi fitur independen (X) dan target (Y yaitu SalePrice).

Standarisasi (Normalisasi):
Dilakukan menggunakan StandardScaler dari Scikit-Learn pada seluruh atribut numerik. Proses ini membuat seluruh data numerik memiliki rata-rata 0 dan standar deviasi 1, sehingga model tidak bias terhadap atribut dengan rentang nilai yang besar.

Encoding:
Dilakukan pada seluruh atribut kategorikal menggunakan metode *One-Hot Encoding*. Fitur nominal yang berupa teks diubah menjadi kolom-kolom biner (0 dan 1). Hal ini menyebabkan jumlah dimensi kolom bertambah secara signifikan.

5. Reduksi Dimensi

Karena jumlah kolom bertambah banyak setelah proses *One-Hot Encoding*, dilakukan reduksi dimensi untuk efisiensi komputasi.



Berdasarkan matriks korelasi, terlihat ada beberapa fitur yang sangat berkorelasi positif dengan harga rumah, seperti OverallQual dan GarageCars. Ditemukan juga tumpang tindih informasi, misalnya antara GarageCars (kapasitas mobil) dan GarageArea (luas garasi) yang sangat berkorelasi satu sama lain, sehingga salah satunya bisa diabaikan.

Principal Component Analysis (PCA):
Untuk mereduksi seluruh fitur yang sudah di-*encode*, PCA diterapkan dengan target mempertahankan 95% varians data (n_components=0.95). Hasilnya, ratusan kolom fitur berhasil dikompresi menjadi jumlah komponen utama (PC) yang jauh lebih sedikit.

6. Ringkasan Akhir

Setelah seluruh tahapan praproses selesai, dataset yang tadinya kotor dan tidak terstandarisasi kini telah menjadi dataset yang bersih (tanpa *missing values*), bebas dari pencilan ekstrem pengganggu, memiliki skala numerik yang seragam, atribut teks telah menjadi numerik biner, dan dimensinya telah direduksi secara optimal.